

# Machine Learning Techniques

**Shyi-Chyi Cheng (鄭錫齊)**

**Email: [csc@mail.ntou.edu.tw](mailto:csc@mail.ntou.edu.tw)**

**Tel: 02-24622192-6653**

# 章節目錄

- ❖ 第一章 簡介
- ❖ 第二章 Python入門
- ❖ 第三章 貝氏定理回顧
- ❖ 第四章 線性分類器
- ❖ 第五章 非線性分類器
- ❖ 第六章 誤差反向傳播法
- ❖ 第七章 與學習有關的技巧
- ❖ 第八章 卷積神經網路
- ❖ 第九章 深度學習


# 卷積神經網路(CNN)

## 學習重點

- ❖ CNN在全連結層的網路中，新加入卷積層及池化層。
- ❖ 使用Python之`im2col`(將影像展開成陣列的函數)，就可以輕鬆快速執行卷積層及池化層。
- ❖ 將CNN視覺化，可以瞭解加深層數之後，擷取出的高階資料模樣。
- ❖ CNN的代表網路包括LeNet與AlexNet
- ❖ 大數據與GPU對深度學習發展的重要貢獻。

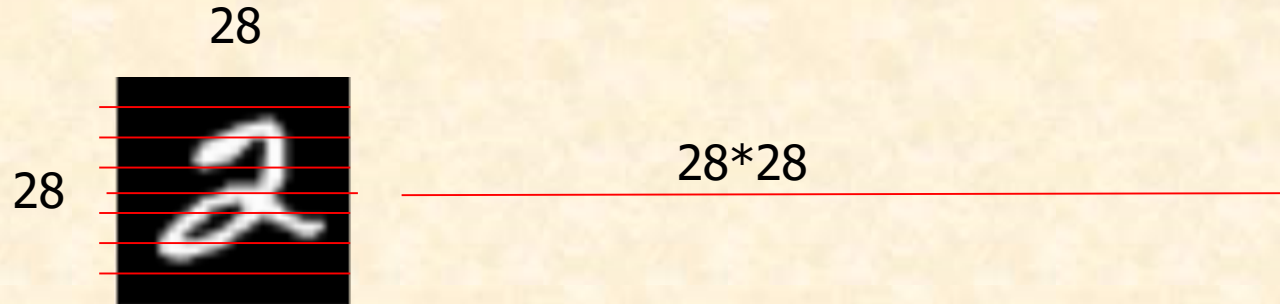
## 整體架構

- ❖ 卷積神經網路(convolutional neural network; CNN)已廣泛應用在各種辨識相關的應用。
- ❖ CNN在全連結(Affine)層的網路中，新加入卷積層(convolution)及池化(Pooling)層。



## 全連結(Affine)層的問題


- ❖ 全連結(Affine)層忽略資料的形狀



- ❖ 例如影像資料包含水平、垂直、及顏色三維形狀，而神經網路之Affine層要求把資料排列成一維資料(平面結構)
- ❖ 資料形狀具重要的空間資訊，不應被去除
- ❖ 卷積層的目的在於維持資料的形狀資訊，以利產生包含形狀資訊的特徵圖(feature map)

# 卷積運算

- ❖ 在卷積層執行的處理叫卷積運算
- ❖ 卷積運算是一種濾鏡(Filter)運算




輸入資料

卷積運算 濾鏡(核, kernel)

# 卷積運算


- ❖ 在卷積層執行的處理叫卷積運算
- ❖ 卷積運算是一種濾鏡(Filter)運算






# 卷積運算

- ❖ 在卷積層執行的處理叫卷積運算
- ❖ 卷積運算是一種濾鏡(Filter)運算




## 卷積運算

- ❖ 在卷積層執行的處理叫卷積運算
- ❖ 卷積運算是一種濾鏡(Filter)運算




## 卷積運算

- ❖ 在卷積層執行的處理叫卷積運算
- ❖ 卷積運算是一種濾鏡(Filter)運算



## 卷積運算於CNN之運作

- ❖ 在卷積層執行的處理叫卷積運算
- ❖ 卷積運算是一種濾鏡(Filter)運算



輸入資料

卷積運算 濾鏡(權重)

偏權值

神經元  
輸出資料

## 填補(Padding)

0	0	0	0	0	0
0	1	2	3	0	0
0	0	1	2	3	0
0	3	1	0	2	0
0	2	3	0	1	0
0	0	0	0	0	0

(4,4)  
輸入資料(Padding: 1)



2	0	1
0	1	2
1	0	2

(3, 3)  
濾鏡(核, kernel)



7	12	10	2
4	15	17	10
10	5	14	6
8	10	4	3

(4,4)  
輸出資料

## 步幅(Stride)

- ❖ 套用濾鏡的位置間隔稱作步幅
- ❖ Stride =2 的例子

1	2	3	0	1	2	3
0	1	2	3	0	1	2
3	0	1	2	3	0	1
2	3	0	1	2	3	0
1	2	3	0	1	2	3
0	1	2	3	0	1	2
3	0	1	2	3	0	1

\*

2	0	1
0	1	2
1	0	2



15		

## 步幅(Stride)

- ❖ 套用濾鏡的位置間隔稱作步幅
- ❖ Stride =2 的例子

1	2	3	0	1	2	3
0	1	2	3	0	1	2
3	0	1	2	3	0	1
2	3	0	1	2	3	0
1	2	3	0	1	2	3
0	1	2	3	0	1	2
3	0	1	2	3	0	1

\*

2	0	1
0	1	2
1	0	2



15	17	

## 輸出資料的大小

- ❖ 令輸入資料大小為 $(H, W)$ ，濾鏡大小為 $(FH, FW)$ ，Padding =  $P$ ，Stride =  $S$
- ❖ 則輸出資料的大小 $(OH, OW)$

$$OH = \frac{H + 2P - FH}{S} + 1$$

$$OW = \frac{W + 2P - FW}{S} + 1$$



# 三維資料的卷積運算

4	2	1	2
2	1	2	4
1	2	4	2
2	4	2	1

\*

4	0	2
0	1	0
1	0	2



28	20
20	22



3	0	6	5
0	6	5	3
6	5	3	0
5	3	0	6

\*

0	1	3
3	1	2
2	3	0



49	71
69	38



92	107
95	75

1	2	3	0
0	1	2	3
3	1	0	2
2	3	0	1

\*

2	0	1
0	1	2
1	0	2




15	16
6	15




## 用區塊來思考

- ❖ 三維卷積運算中的資料或濾鏡想像成三維立方體區塊，比較容易思考。




# 多個濾鏡的卷積運算

- ❖ 三維卷積運算中的資料或濾鏡想像成三維立方體區塊，比較容易思考。



# 多個濾鏡、加上偏權值的卷積運算

- ❖ 三維卷積運算中的資料或濾鏡想像成三維立方體區塊，比較容易思考。



$(C, H, W)$   
輸入資料



$(FN, C, FH, FW)$   
濾鏡



$(FN, OH, OW) +$


$(FN, 1, 1)$   
偏權值



$(FN, OH, OW)$   
輸入資料

# 多個濾鏡、加上偏權值及批次處理的卷積運算


- ❖ 三維卷積運算中的資料或濾鏡想像成三維立方體區塊，比較容易思考。



# 池化層(Pooling)


- ❖ 池化層是縮小垂直、水平空間的運算。
- ❖ 以下是最大化池化層(Max Pooling)之範例

1	2	3	0
0	1	2	3
3	1	0	2
2	3	0	1



2	

1	2	3	0
0	1	2	3
3	1	0	2
2	3	0	1




2	3

1	2	3	0
0	1	2	3
3	1	0	2
2	3	0	1



2	3
3	

1	2	3	0
0	1	2	3
3	1	0	2
2	3	0	1




2	3
3	2

也可使用其他的池化層函數，例如取平均值、取中值等

## 池化層的特色


- ❖ 沒有學習參數(使用制式函數)
- ❖ 色板數量不變

3	0	6	5
0	6	5	3
6	5	3	0
5	3	0	6




6	6
6	6

1	2	3	0
0	1	2	3
3	1	0	2
2	3	0	1



2	3
3	2

4	2	1	2
2	1	2	4
1	2	4	2
2	4	2	1



4	4
4	4



## 池化層的特色

- ❖ 對微小變化很穩健(Robust)
  - 區域內之微小變化值會被忽略。

3	0	6	5
0	6	5	3
6	5	3	0
5	3	0	6



6	6
6	6

1	2	3	0
0	1	2	3
3	1	0	2
2	3	0	1



2	3
3	2

4	2	1	2
2	1	2	4
1	2	4	2
2	4	2	1



4	4
4	4



## Python執行捲積層/池化層

### ❖ 製作捲積層需要用到4維陣列

➤ CNN各層流動的資料是四維陣列，例如(10, 1, 28, 28)代表10個高度28、寬度28、1個色板的輸入影像

➤ Python Code

```
>>> x = np.random.rand(10, 1, 28, 28)    #隨機產生資料
```

```
>>> x.shape
```

```
(10, 1, 28, 28)
```

```
>>> x[0].shape    #存取第一筆資料
```


```
(1, 28, 28)
```

```
>>> x[0, 0].shape #存取第一筆資料的第一個色板
```

```
(28, 28)
```

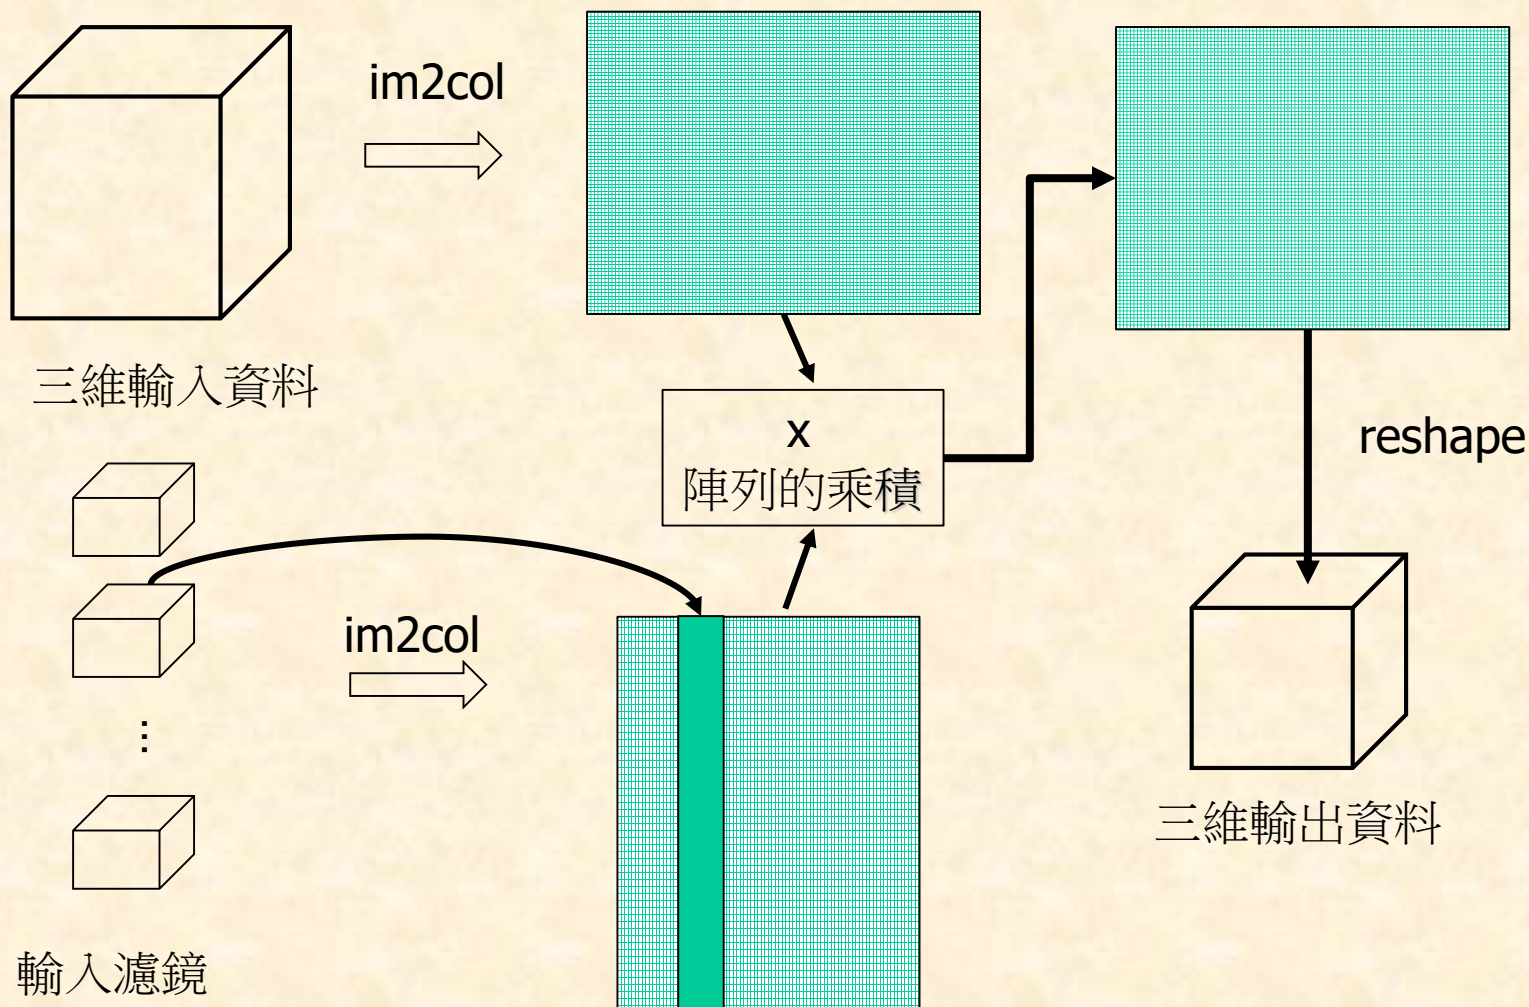
## Python執行捲積層/池化層

- ❖ 利用內建函數`im2col`製作捲積層處理需要用到4維陣列
- ❖ `im2col` 是可以針對套用的濾鏡(權重)輕鬆展開資料的函數。
- ❖ `im2col` 可以針對套用的濾鏡的位子，輕鬆展開資料的函數。



## Python執行捲積層/池化層

- ❖ 利用`im2col`展開輸入資料，之後只要把捲積濾鏡(權重)展開成一行，計算兩個陣列的乘積即可。




# im2col Code

```
def im2col(input_data, filter_h, filter_w, stride=1, pad=0):
    """
    Parameters
    -----
    input_data : (批次大小, 色板個數, 高度, 寬度)的4維張量
    filter_h : 濾鏡的高度
    filter_w : 濾鏡的寬度
    stride : 步幅
    pad : padding數
    Returns
    -----
    col : 2維陣列
    """
    N, C, H, W = input_data.shape
    out_h = (H + 2*pad - filter_h)//stride + 1
    out_w = (W + 2*pad - filter_w)//stride + 1
    img = np.pad(input_data, [(0,0), (0,0), (pad, pad), (pad, pad)], 'constant')
    col = np.zeros((N, C, filter_h, filter_w, out_h, out_w))
    for y in range(filter_h):
        y_max = y + stride*out_h
        for x in range(filter_w):
            x_max = x + stride*out_w
            col[:, :, y, x, :, :] = img[:, :, y:y_max:stride, x:x_max:stride]
    col = col.transpose(0, 4, 5, 1, 2, 3).reshape(N*out_h*out_w, -1)
```

# im2col 函數

```
x1 = np.random.rand(1, 3, 7, 7)
col1 = im2col(x1, 5, 5, stride = 1, pad = 0)
print(col1.shape)  #(9, 75)
```



## 使用im2col執行捲積層

```
class Convolution:
```

```
    def __init__(self, W, b, stride=1, pad=0):
```

```
        self.W = W
```


```
        self.b = b
```

```
        self.stride = stride
```

```
        self.pad = pad
```

transpose(0, 3, 1, 2)

形狀 (N, H, W, C)  
索引值 0, 1, 2, 3



形狀 (N, C, H, W)  
0, 3, 1, 2

```
    def forward(self, x):
```

```
        FN, C, FH, FW = self.W.shape
```

```
        N, C, H, W = x.shape
```

```
        out_h = 1 + int((H + 2*self.pad - FH) / self.stride)
```

```
        out_w = 1 + int((W + 2*self.pad - FW) / self.stride)
```

```
        col = im2col(x, FH, FW, self.stride, self.pad)
```

```
        col_W = self.W.reshape(FN, -1).T
```

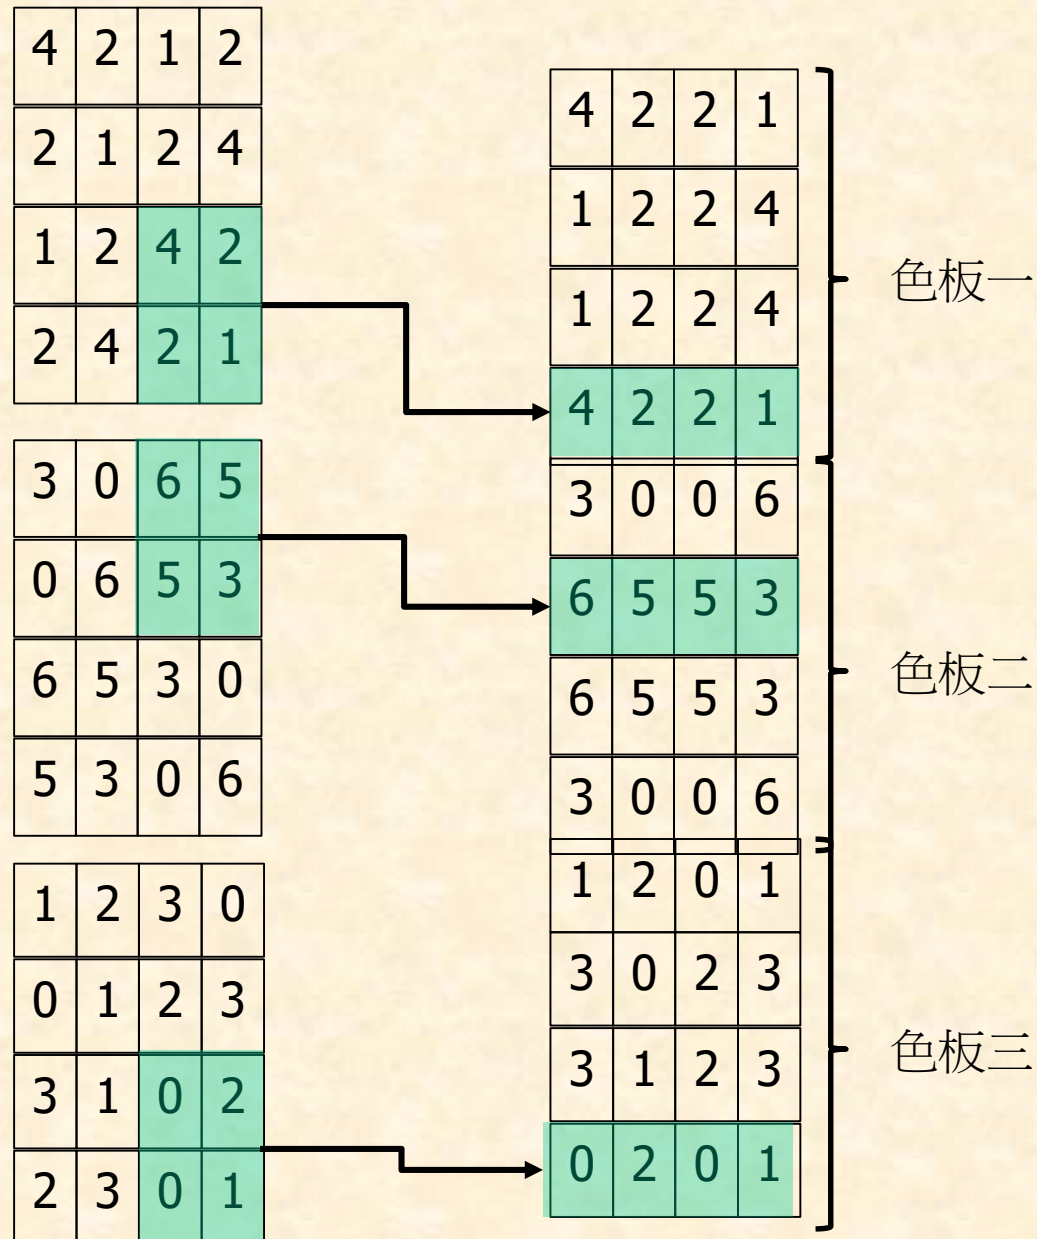
```
        out = np.dot(col, col_W) + self.b
```

```
        out = out.reshape(N, out_h, out_w, -1).transpose(0, 3, 1, 2)
```

```
        return out
```

## 執行池化層

- ❖ 池化層的執行過程跟卷積層一樣，利用`im2col`展開輸入資料，但是池化層各色板的運算是彼此獨立，這點跟卷積層不一樣。





# 執行池化層

❖ 展開後，針對各列進行運算

輸入資料

4	2	1	2
2	1	2	4
1	2	4	2
2	4	2	1

展開

4	2	2	1
1	2	2	4
1	2	2	4
4	2	2	1

輸入資料

3	0	6	5
0	6	5	3
6	5	3	0
5	3	0	6

展開

3	0	0	6
6	5	5	3
6	5	5	3
3	0	0	6

輸入資料

1	2	3	0
0	1	2	3
3	1	0	2
2	3	0	1

展開

1	2	0	1
3	0	2	3
3	1	2	3
0	2	0	1

max

4
4
4
4
6
6
6
6
2
3
3
2

reshape

4	4
4	4

輸出資料

reshape

6	6
6	6

輸出資料

reshape

2	3
3	2

輸出資料



# Python執行池化層

```
class Pooling:
```

```
    def __init__(self, pool_h, pool_w, stride=1, pad=0):
```

```
        self.pool_h = pool_h
```

```
        self.pool_w = pool_w
```

```
        self.stride = stride
```

```
        self.pad = pad
```

```
    def forward(self, x):
```

```
        N, C, H, W = x.shape
```

```
        out_h = int(1 + (H - self.pool_h) / self.stride)
```

```
        out_w = int(1 + (W - self.pool_w) / self.stride)
```

```
        # 展開(1)
```

```
        col = im2col(x, self.pool_h, self.pool_w, self.stride, self.pad)
```

```
        col = col.reshape(-1, self.pool_h*self.pool_w)
```

```
        # 最大值 (2)
```

```
        arg_max = np.argmax(col, axis=1)
```

```
        out = np.max(col, axis=1)
```

```
        # 調整形狀 (3)
```


```
        out = out.reshape(N, out_h, out_w, C).transpose(0, 3, 1, 2)
```

```
        return out
```

# Python執行CNN

- ❖ 以管線作業方式組合各層的功能，就可完成CNN之基本執行工作。

conv - relu - pool - affine - relu - affine - softmax



# Python執行CNN

## ❖ 單存的CNN引數(參數)

`input_dim` : 輸入資料的(色板、高度、寬度)維度

`conv_param`: 卷積層的超參數(字典)。Key 如下

--- `filter_num`: 濾鏡的數量

--- `filter_size`: 濾鏡的大小

--- `stride`: 步幅

--- `pad`: 填補

`hidden_size` : 隱藏層(全連接)的神經元個數

`output_size` : 輸出層(全連接)的神經元個數(MNIST的例子為10)

`activation` : 'relu' or 'sigmoid'

`weight_init_std` : 初始化時的權重標準偏差的指定 (e.g. 0.01)

--- 'relu'時採用「He的初期值」設定

--- 'sigmoid'時採用「Xavier的初期值」設定

## SimpleConvNet的初始化

```
def __init__(self, input_dim=(1, 28, 28),
              conv_param={'filter_num':30, 'filter_size':5, 'pad':0, 'stride':1},
              hidden_size=100, output_size=10, weight_init_std=0.01):
    filter_num = conv_param['filter_num']
    filter_size = conv_param['filter_size']
    filter_pad = conv_param['pad']
    filter_stride = conv_param['stride']
    input_size = input_dim[1]
    conv_output_size = (input_size - filter_size + 2*filter_pad) / filter_stride + 1
    pool_output_size = int(filter_num * (conv_output_size/2) *
                           (conv_output_size/2))
```

# SimpleConvNet的初始化

# 權重的初始化

```
self.params = {}  
self.params['W1'] = weight_init_std * \  
    np.random.randn(filter_num, input_dim[0], filter_size, filter_size)  
self.params['b1'] = np.zeros(filter_num)  
self.params['W2'] = weight_init_std * \  
    np.random.randn(pool_output_size, hidden_size)  
self.params['b2'] = np.zeros(hidden_size)  
self.params['W3'] = weight_init_std * \  
    np.random.randn(hidden_size, output_size)  
self.params['b3'] = np.zeros(output_size)
```

## SimpleConvNet的初始化

# 產生必要層

```
self.layers = OrderedDict()
```

```
self.layers['Conv1'] = Convolution(self.params['W1'], self.params['b1'],  
                                   conv_param['stride'], conv_param['pad'])
```

```
self.layers['Relu1'] = Relu()
```

```
self.layers['Pool1'] = Pooling(pool_h=2, pool_w=2, stride=2)
```

```
self.layers['Affine1'] = Affine(self.params['W2'], self.params['b2'])
```

```
self.layers['Relu2'] = Relu()
```

```
self.layers['Affine2'] = Affine(self.params['W3'], self.params['b3'])
```

```
self.last_layer = SoftmaxWithLoss()
```

## SimpleConvNet的predict及損失函數計算

```
def predict(self, x):  
    for layer in self.layers.values():  
        x = layer.forward(x)
```

```
    return x
```

```
def loss(self, x, t):  
    y = self.predict(x)  
    return self.last_layer.forward(y, t)
```



# SimpleConvNet的誤差反向傳播法及梯度計算

```
def gradient(self, x, t):  
    # forward  
    self.loss(x, t)  
    # backward  
    dout = 1  
    dout = self.last_layer.backward(dout)  
    layers = list(self.layers.values())  
    layers.reverse()  
    for layer in layers:  
        dout = layer.backward(dout)  
    # 設定  
    grads = {}  
    grads['W1'], grads['b1'] = self.layers['Conv1'].dW, self.layers['Conv1'].db  
    grads['W2'], grads['b2'] = self.layers['Affine1'].dW, self.layers['Affine1'].db  
    grads['W3'], grads['b3'] = self.layers['Affine2'].dW, self.layers['Affine2'].db  
  
    return grads
```





## SimpleConvNet的執行結果

- ❖ 執行前必須先行訓練(請參考ch07/train\_convent.py)
- ❖ 執行結果(MNIST DATASET)
  - 訓練資料的辨識率(inside testing): 99.28%
  - 測試資料的辨識率(outside testing): 98.96%

利用重疊更多層(深度學習)時，測試資料的辨識率可達99%

# CNN的視覺化

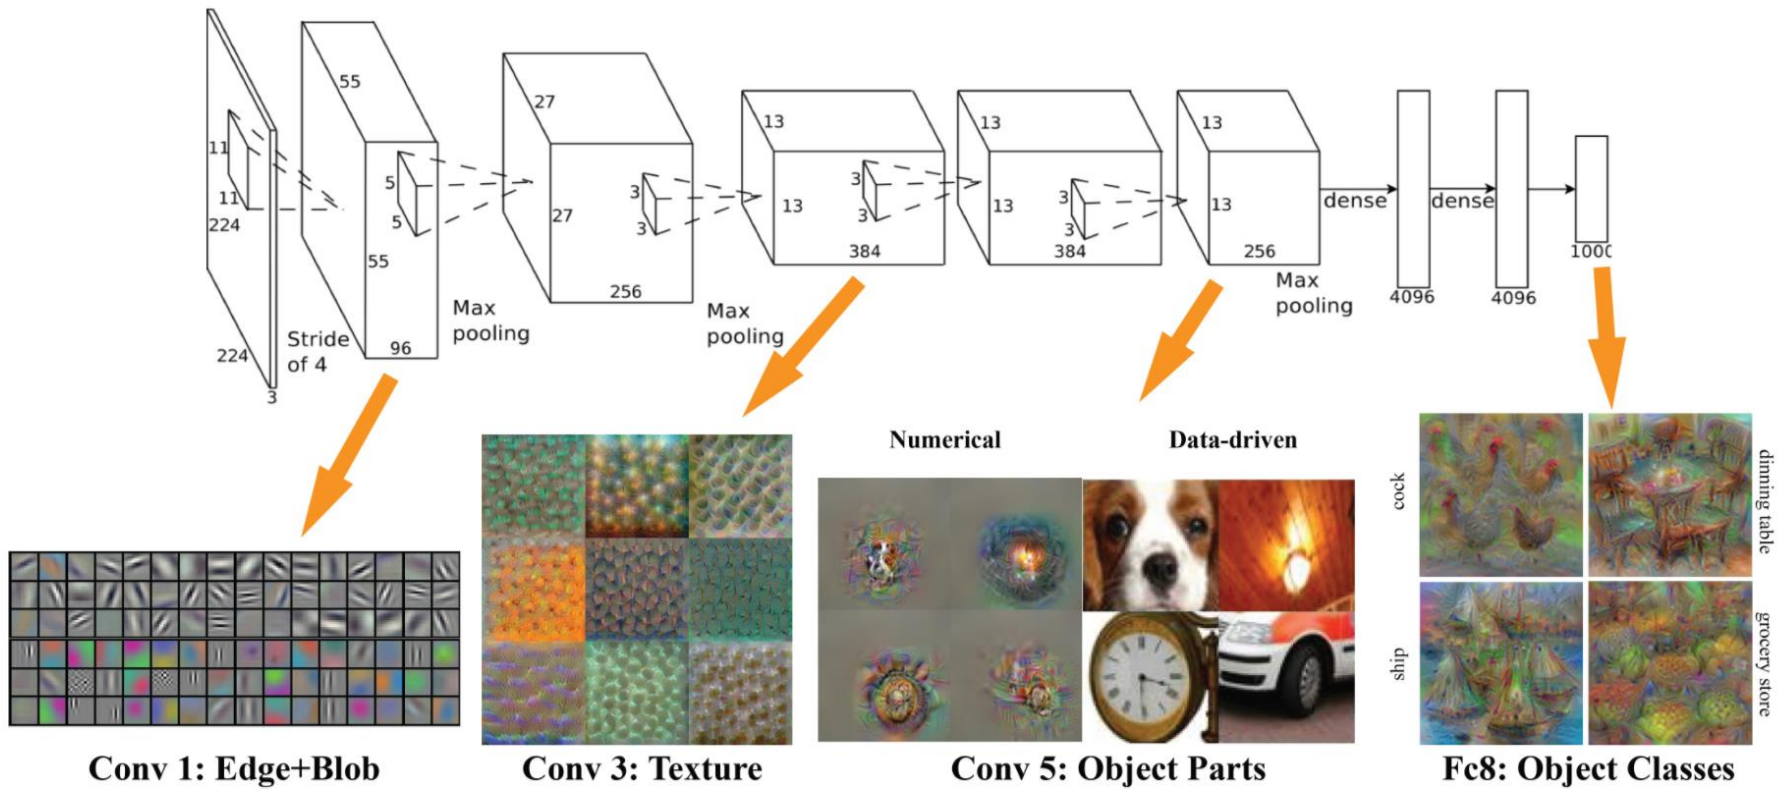
- ❖ 視覺化第一層權重
  - 形狀:(30, 1, 5, 5)



學習前: 隨意初始化濾鏡

學習後: 擷取輸入影像的各種初階結構(線邊)特徵


# AlexNet的各層視覺化結果



# CNN的鼻祖

## ❖ CNN的鼻祖

### ➤ LeNet (1998)




PROC. OF THE IEEE, NOVEMBER 1998

## Gradient-Based Learning Applied to Document Recognition

Yann LeCun, Léon Bottou, Yoshua Bengio, and Patrick Haffner

# 現代版的CNN

## ❖ AlexNet (2012)



## ImageNet Classification with Deep Convolutional Neural Networks

**Alex Krizhevsky**  
University of Toronto  
[kriz@cs.utoronto.ca](mailto:kriz@cs.utoronto.ca)

**Ilya Sutskever**  
University of Toronto  
[ilya@cs.utoronto.ca](mailto:ilya@cs.utoronto.ca)

**Geoffrey E. Hinton**  
University of Toronto  
[hinton@cs.utoronto.ca](mailto:hinton@cs.utoronto.ca)

## LeNet vs. AlexNet

- ❖ 結構相似
- ❖ AlexNet做了哪些改善
  - 使用ReLU函數
  - 使用LRN(Local Response Normalization)局部性正規化層。
  - 使用Dropout
- ❖ 20年前LeNet無GPU及雲端系統可供平行處理，因學習速度太慢，無法獲得該有的重視。

Any Questions?